

# **Ciclo de vida >>>>>>**

# **Engenharia de**

# **dados**

# Sumário

- Ciclo de vida de dados
- Ciclo de vida de Engenharia de Dados
  - Etapas
  - Elementos subjacentes
- Estudo de caso: Brasil Participativo




**Ciclo de vida dos dados**

**X**

**Ciclo de vida da  
Engenharia de dados**




# Ciclo de vida de dados



# **Ciclo de vida dos dados**


**Ciclo de vida da  
Engenharia de dados**

# Ciclo de vida da Engenharia de dados




---

## Elementos subjacentes




# #1 Geração

- Sistema de origem dos dados (diversos tipos)
- Geralmente o engenheiro de dados não é proprietário nem controle direto sobre ele.
- Necessário compreender:
  - o funcionamento, como os dados são gerados, a frequência e variedade.
  - por quanto tempo são mantidos.
  - há dados duplicados?
  - mudanças de schema
  - quem provê esses dados?
  - leitura da fonte afeta o desempenho dela?
  - é baseada em eventos?



# #2 Armazenamento

- Onde armazenar influencia em todas as etapas do ciclo de vida.
- Considerações:
  - É compatível com a velocidade de escrita e leitura exigidas pela arquitetura?
  - A escolha da tecnologia foi pensando nas características do funcionamento dela? (Quantidade de acessos, taxa de atualizações, ...)
  - Esse sistema de armazenamento lidará com a escala futura prevista?
  - O sistema de armazenamento é independente de esquema? Esquema flexível (Cassandra) ou Esquema fixo (um data warehouse em nuvem)?
  - compliance regulatório e a soberania de dados? É possível armazenar seus dados em determinadas localizações geográficas?



# #3 Ingestão

- Transferir os dados da origem para um armazenamento da arquitetura de engenharia de dados.
- Considerações:
  - os sistemas estão ingerindo os dados de maneira confiável?
  - qual o destino dos dados após a ingestão?
  - com qual frequência os dados serão acessados?
  - qual o volume que os dados costumam chegar?
  - em que formato estão os dados? (uso deles em sistemas downstream)
  - Os dados de origem em condição para uso imediato? O que pode causar a inutilização?
  - Caso os dados sejam se uma fonte de streamin, é necessário transformá-los antes de chegar no destino?



# #4 Transformação

- Mudar da forma original para torná-los úteis para casos de uso downstream
- Rastreabilidade (Linhagem dos dados)
- Custo computacional
- Qualidade de dados
- Considerações:
  - Qual é o custo e o retorno sobre investimento (ROI) da transformação? Qual é o valor comercial associado?
  - A transformação é simples e isolada?
  - Quais são as regras de negócios suportadas pelas transformações



# #5 Disponibilização

Onde você obtém o valor dos dados ingeridos

## Análise

- Gerar relatórios ou dashboards
- BI
- Analise operacional
- Analise incorporada



## ML

- Data Lake / Lakehouse
- Data Warehouse
- Feature store
- Vetorização de dados
- Verificar a qualidade dos dados para o uso em ML



## ETL Reverse

- Retorna os dados tratados novamente na fonte.
- Muito utilizado no caso de BI's
- Uso de API's, banco de dados ou webhooks

# #6.1 Elementos subjacentes

## Segurança

- Controle de acesso para:
  - Dados
  - Sistema
- Princípio do privilégio mínimo
- Por quanto tempo

## Gerenciamento de dados

- Abrange desenvolvimento, execução, supervisão de programas e práticas
- Governança de dados
- Modelagem e desing de dados
- Integridade dos dados
- Linhagem de dados
- Gerenciamento do ciclo de vida



## DataOps

- Aprimorar os processos e os produtos relacionados a dados
- Inovação e experimentação
- Qualidade de dados
- Colaboração entre pessoas, times, tecnologias e ambientes
- Monitoramento e transparência dos resultados
- Três aspectos:
  - Automação
  - Observabilidade e monitoramento
  - Resposta à incidentes

# #6.2 Elementos subjacentes

## Arquitetura de dados

- Analise de compensações
- Desenvolvimento ágil
- Gerar valor para o negócio
- Flexível e preparada a mudanças
- Sustentabilidade
- Eficiência

## Orquestração

- Coordenar fluxos de trabalho
- Programar tarefas
- Gerenciar tarefas




## Engenharia de Software

- Habilidade de programação e codificação
- Padrões de design de software
- Testes e depuração

# Estudo de caso:




# Arquitetura de Engenharia de dados




# Migração para o SaaS

Mudaça na origem dos dados

**BP Single Tenant**



**BP Multi Tenant**




# Estratégia para migração

## Nova forma de ingestão

Banco brasil participativo

Banco analytics



kafka + debezium

- Todas as instâncias sempre seguem a mesma versão do decidim, logo o mesmo esquema