PROJETO INTEGRADO / BANCO DE DADOS 2

InflaTrack

Guia detalhado de arquitetura, escolhas e entregaveis

Material de apoio para apresentar e entender a parte tecnica

O que voce vai encontrar

Este guia organiza a documentacao do repositorio para explicar o problema de negocio, o desenho dos dados, a razao das tecnologias, o que ja foi comprovado e o que continua planejado. O estado descrito foi conferido em 18 de outubro de 2026; os numeros de carga sao os registrados nas evidencias da Entrega 2, com suas respectivas datas.

Resumo honesto: o projeto tem ingestao real de varias fontes, persistencia PostgreSQL para o lado transacional e DuckDB para analise, alem de Bronze Delta em parte das fontes. O pipeline analitico completo com dbt, modelos comuns Silver/Gold e painel ainda e trabalho futuro.

Como usar na apresentacao

- Comece pela pergunta do lojista, nao pela lista de ferramentas.
- Explique a separacao: PostgreSQL protege mudancas de preco; DuckDB facilita cruzamentos analiticos.
- Mostre os dados medidos e deixe claro onde ha limitacoes pendentes.

Projeto Integrado - Banco de Dados 2 / Engenharia de Software / FCTE-UnB

1. O problema que o InflaTrack resolve

O InflaTrack e uma plataforma de dados pensada para pequenos e medios lojistas. A pergunta central e: **quanto a inflacao do setor e da regiao do lojista subiu, e qual reajuste de preco ajuda a preservar a margem?** A ideia e reunir indices oficiais e informacoes do proprio lojista para apoiar uma decisao que hoje costuma depender de pesquisa manual e intuicao.

O lojista cadastra seus produtos e associa cada produto a uma categoria comparavel do IPCA. O sistema usa a variacao de preco observada naquela categoria, periodo e localidade para apresentar contexto e uma sugestao. A proposta e dar transparencia ao fundamento da sugestao, nao substituir a decisao comercial do lojista.

As 11 perguntas documentadas

Grupo	Exemplos de pergunta	Dados que entram
Nucleo (1-5)	Inflacao do setor em 12 meses; sazonalidade; poder de compra desde 2006; diferenca Brasil/regiao; reajuste minimo.	IPCA/INPC + produto e localidade do lojista
Expansoes macro (6, 8, 9)	Impacto do dolar em importados; inflacao junto do PIB; repasse agora ou absorcao diante da Selic.	Dolar, PIB, Selic + IPCA
Expansoes analiticas (7, 10, 11)	Seca e preco agricola; volatilidade intradiaria do dolar; vendas e aperto monetario.	Clima, boletins de cambio, IPCA e vendas

As cinco primeiras sao o nucleo originalmente usado para orientar o modelo de dados. As perguntas 6 a 11 ampliam o escopo e tornam visiveis dependencias adicionais: por exemplo, a pergunta 11 exige vendas do lojista, dado que ainda nao esta disponivel como fonte no pipeline. O catalogo completo e a fonte autoritativa para a redacao de cada pergunta.

> **Mensagem de negocio:** a tecnologia foi escolhida para dar uma resposta justificavel e reproduzivel, conectando uma categoria oficial de inflacao ao produto real do comerciante.

2. Como a arquitetura organiza os dados

O desenho combina dois fluxos porque o projeto tem dois tipos de trabalho. O fluxo analitico coleta dados externos em lotes e prepara cruzamentos. O fluxo transacional registra lojistas, produtos e reajustes, onde cada escrita precisa ser consistente.



FLUXO TRANSACIONAL (paralelo)

Lojista + produto + reajustes + referencia IPCA -> PostgreSQL (integridade e transacoes)

Estado em 18/10/2026: Raw e Bronze parciais/ativas; Silver e Gold comuns ainda sao alvo.

Camadas de dados: significado e estado

Camada	O que guarda	Estado registrado
Raw	Resposta original da fonte, normalmente JSON ou HTML comprimido em gzip.	Existe por fonte; historicos importados podem ter sido reserializados por fluxos antigos.
Bronze	Payload tipado e metadados de origem, sem regras analiticas comuns.	Delta Lake em varias fontes; algumas cargas legadas ainda usam Parquet simples.
Silver	Dados limpos, deduplicados e alinhados a contratos comuns.	Planejada com dbt; dbt e pasta models/ ainda nao existem.
Gold	Indicadores e tabelas analiticas que respondem as perguntas de negocio.	Camada dimensional comum planejada. Tabelas/views atuais sao especificas por fonte.

Raw permite voltar ao que a API entregou. Bronze registra a extracao da fonte. Silver e o lugar proposto para limpar e padronizar. Gold combina as fontes para perguntas especificas. Essas palavras descrevem uma arquitetura alvo; nao significam que todos os dados ja percorrem hoje as quatro camadas.

DuckDB nao e uma camada: e o banco analitico usado/planejado para consultar dados. O PostgreSQL tambem nao e parte do Medallion: ele fica ao lado, no fluxo de cadastro e reajustes.

3. Por que PostgreSQL e DuckDB convivem

A escolha nao e ter dois bancos para fazer a mesma coisa. Eles protegem tipos de acesso diferentes.

Aspecto	PostgreSQL (transacional / OLTP)	DuckDB (analitico / OLAP)
Papel	Lojista, produto, reajuste e referencias relacionais, incluindo observacoes do IPCA no fluxo atual.	Consultas sobre fontes publicas e cruzamentos analiticos no arquivo compartilhado.
Por que serve	Chaves estrangeiras, CHECK/UNIQUE e transacoes garantem que uma alteracao de preco tenha integridade.	SQL sobre Parquet e varias fontes locais; dispensa operar um servidor analitico para o volume atual.
Custo / limite	Exige migrations e um servico local; e mais infraestrutura que um arquivo.	Arquivo simples de compartilhar, mas apenas um processo escritor por arquivo ao mesmo tempo.
Decisao	Nao e o destino pretendido para todos os cruzamentos analiticos.	Cargas sao serializadas; aumenta a importancia de backup do arquivo unico.

Exemplo: aplicar um reajuste

Quando o preco muda, o projeto registra um novo evento em **reajuste**, em vez de sobrescrever silenciosamente o preco anterior. O preco corrente e calculado pela view **produto_preco_atual**: usa o ultimo reajuste, ou o preco inicial caso nao exista. O Postgres pode validar nessa operacao que os valores sao positivos, que o novo preco difere do anterior e que o produto existe.

A analise de muitas fontes, por outro lado, se beneficia de consultas SQL locais e joins no mesmo arquivo DuckDB. O ADR 0002 escolhe um unico arquivo porque o produto precisa combinar as fontes; o custo assumido e concentrar o risco do arquivo e serializar os escritores. Os volumes medidos que motivaram o ADR eram modestos: 26.781 observacoes de commodities e 2.806 do PIB setorial na camada servida (medicao de 25/09/2026).

> **Regra mental para apresentar:** Postgres cuida do que o lojista muda; DuckDB cuida de ler e combinar conjuntos de dados para analise. Uma consulta cruzada usa SQL/JOIN; uma mudanca de preco usa transacao.

4. Escolhas tecnologicas em uso

A justificativa de uma stack nao e dizer que uma ferramenta e 'a melhor'. E explicar qual problema ela resolve aqui, que alternativa foi considerada e qual limite a equipe aceita.

Tecnologia	Por que foi escolhida	Custo ou limite
Python 3.12	Uma linguagem para clientes HTTP, transformacoes, Delta/Arrow e orquestracao. Mantem a equipe no mesmo ecossistema de dados.	Clientes usam httpx e requests; reduzir a duplicacao para httpx e uma melhoria possivel, nao uma decisao adicional.
PostgreSQL 16.4	Banco relacional com transacoes, integridade referencial e SQL conhecido pela Squad; adequado a cadastro e historico de preco.	Requer migrations e um servico. Fica limitado ao dominio transacional e a integracao atual do IPCA.
DuckDB	Banco analitico embarcado: SQL local e joins entre fontes no mesmo arquivo, sem manter cluster de analise.	Um escritor por arquivo; cargas precisam ser serializadas; arquivo unico concentra risco.
Parquet + Delta Lake	Parquet e colunar e interoperavel. O log Delta adiciona commits/versionamento, idempotencia e trilha de revisoes na Bronze.	Mais dependencias e operacao que arquivos Parquet comuns. Algumas fontes ainda estao no formato legado.
PyArrow	Formato de troca entre DataFrames, Arrow, Delta Lake e leitores analiticos; permite tipagem e interoperabilidade.	Mais uma API de tipos e schemas a conhecer.
pandas	Facilita converter payloads variados em tabelas e lotes tabulares nos ingestores atuais.	Pode ser reduzido em cargas futuras que operem diretamente com Arrow; nao e o motor de consulta.

4. Escolhas tecnologicas em uso (continua)

Tecnologia	Por que foi escolhida	Custo ou limite
Dagster	Orquestra ativos de dados, dependencias, retries, particoes e backfills. A ideia de 'ativo atualizado' combina com fontes e tabelas.	DuckDB precisa de pool de escritor; dagster-dbt so faz sentido quando o projeto dbt existir.
Docker Compose	Sobe Postgres e ferramentas locais de forma reproduzivel, sem exigir servico hospedado.	Configuracao para desenvolvimento; nao representa alta disponibilidade de producao.
uv + just	uv fixa e sincroniza dependencias; just apresenta comandos do projeto com nomes reproduziveis.	Exigem as ferramentas locais indicadas no onboarding.
MkDocs Material	Documentacao versionada como site estatico; build estrito encontra links invalidos antes da publicacao.	E a camada de documentacao, nao runtime do produto.
psycopg + python-dotenv	psycopg conecta os modulos Python ao Postgres; dotenv le chaves locais sem por segredo no codigo.	Configuracao sensivel ainda depende do ambiente e de proteger o arquivo .env.
Ruff + pytest	Lint, formatacao e testes para detectar problemas de codigo e de transformacao.	Cobertura e evidencias variam por fonte; testes nao substituem validacao real contra APIs.
Dagster Webserver + Adminer	Interface local de execucoes e painel opcional para inspecionar o Postgres.	Ferramentas de desenvolvimento/operacao; Adminer nao e a interface do lojista.

Por que nao Airflow, Postgres para tudo ou DuckDB para tudo?

- Dagster se encaixa no pipeline descrito como ativos, particoes e backfills; o projeto nao precisa hoje de um servico geral separado para agendamento.
- Postgres resolve bem consistencia transacional, mas forcar nele toda a analise mistura requisitos e reduz a simplicidade do ambiente local.
- DuckDB reduz o custo da analise local, mas seu escritor serializado nao e uma boa fronteira para edicoes concorrentes de cadastro/preco.
- Parquet puro mantem os dados interoperaveis, mas nao registra sozinho os commits e versoes que a Bronze E2 quer demonstrar; Delta fica sobre Parquet.

5. Tecnologias planejadas e fronteira com o que existe

A documentacao agora separa tecnologias em uso de propostas futuras. Isso e importante para nao apresentar um desenho de destino como se fosse uma aplicacao entregue.

Tecnologia futura	Papel pretendido	Status no repositorio
dbt-core + dbt-duckdb	Modelos SQL, dependencias, testes e linhagem para transformar Bronze em Silver/Gold; regras analiticas ficam fora dos ingestores Python.	Planejado; ainda nao consta no pyproject.toml e nao ha pasta models/.
Streamlit + Plotly	Interface Python com filtros e graficos interativos sobre a Gold.	Planejado; sem painel no repositorio e sem dependencias instaladas.
Jupyter + scikit-learn + MLflow	Explorar dados, treinar/comparar modelos e registrar parametros, metricas e artefatos.	Planejado; adotar depois de existir uma matriz Gold e um experimento reproduzivel.

O que ja roda enquanto a migracao acontece

A E2 adiciona tabelas Delta Bronze e mantem fluxos legados que escrevem Parquet simples ou carregam tabelas especificas diretamente no DuckDB. O banco DuckDB unico existe para os loaders analiticos. Os modulos Dagster orquestram ingestao, mas ainda nao transformacao dbt. O PostgreSQL guarda cadastro/reajuste e recebe observacoes IPCA no fluxo atual.

Por isso o status correto e 'arquitetura em transicao'. O nome historico **data/parquet/** abriga tanto tabelas Delta (arquivos Parquet mais **_delta_log**) quanto alguns Parquet simples. O caminho do arquivo, sozinho, nao diz qual contrato esta em uso; e preciso verificar a fonte e o comando.

> **Frase para a banca:** temos ingestao e Bronze funcionando em parte das fontes, mas Silver e Gold comuns com dbt e a interface de negocio sao o proximo estagio. A arquitetura documenta o alvo e distingue o legado de forma explicita.

6. ADRs: as decisoes e o estado real

ADR significa Architecture Decision Record: um registro curto do contexto, alternativas, decisao, consequencias e gatilho de revisao. O projeto ja tinha ADRs sobre modelagem e bancos; esta revisao tambem ajustou o estado de implementacao para que texto e codigo nao se contradigam.

Registro	Decisao e justificativa	Estado e cuidado
0001 - Origem e cesta IPCA	Preservar revisoes de valores em vez de sobrescreve-las, com dimensao de classificacao por vigencia para lidar com mudancas historicas da cesta.	Parcial. O fato preserva valores diferentes; a tabela de classificacoes ainda sobrescreve o nome por codigo/fonte. A fidelidade da cesta historica ainda nao esta implementada; latencia/disco tambem nao foram medidos.
0002 - DuckDB unico	Um arquivo analitico permite cruzar fontes com JOIN e simplifica distribuicao; um arquivo por fonte aumentaria artefatos e exigiria ATTACH.	Adotado. Tabelas por fonte e cargas em sequencia. Limite: um processo escritor e risco concentrado no arquivo.
0003 - Series BCB	Usar calendario civil e forward fill nos dados legados para vendas em fim de semana/feriado encontrarem o ultimo valor util; registrar observado e buscar dez dias de contexto.	Implementado nos loaders legados de dolar/Selic. A Bronze Delta E2 guarda so observacoes oficiais; a regra ainda precisa ser migrada para a futura Silver.
0004 - Ingestao / CDC	Comparar mecanismo de ingestao/CDC, incluindo Delta vs Iceberg e opcoes de captura logica do Postgres.	Pendente conforme o plano E2. A pagina da stack e um registro nao numerado; nao ocupa ADR 0004.

Por que o ADR 0001 merece atencao

A proposta descreve uma dimensao historica, mas a migration atual restringe a classificacao a uma linha por codigo/fonte e o sincronizador atualiza o nome quando conflita. Assim, se a cesta renomeia uma categoria mantendo o codigo, o nome anterior nao fica consultavel com sua vigencia. A documentacao agora chama isso de pendencia em vez de dizer que a dimensao historica esta pronta.

Essa e uma distincao importante de engenharia: um ADR registra a intencao e os trade-offs; a implementacao precisa ser conferida no schema, nos escritores e na evidencia. O PR atualiza a narrativa e os links, mas nao muda a semantica do banco.

7. Entregaveis registrados na documentacao

A pasta docs/evidencias/e2/ contem nove paginas por frente: IPCA/INPC, commodities, PIB setorial (SIDRA 1846), PIB da China, dos EUA e da Russia, macroeconomia (dolar e Selic juntos), salario minimo e clima. Elas documentam comandos, transformacoes, contagens, checagens, reexecucao e limites por fonte. Os numeros abaixo sao registros dessas execucoes, nao um benchmark novo feito para este guia.

Frente	Entregaveis comprovados	Limite ou observacao
IPCA/INPC - SIDRA	Bronze Delta de respostas e observacoes; importacao de 886 respostas; checagens e reexecucao idempotente documentadas.	Diario de bordo aparece pendente na pagina de evidencia. A classificacao historica por vigencia continua pendente.
Dolar + Selic - BCB	Bronze Delta com respostas e observacoes oficiais; boletins intradiarios do dolar preservados; politica de revisao e checagens registradas.	Ha escrita legada no DuckDB. Forward fill dos loaders legados ainda nao foi migrado para a Bronze Delta/Silver. Diario de bordo pendente.
Commodities - Alpha Vantage	Delta para respostas e cotacoes; 9 simbolos; 31.880 linhas incluindo marcadores sem preco; importacao, reexecucao e checagens documentadas.	Tarefas Bronze E2 por fonte concluidas; diario pendente. Carga/contratos no DuckDB e modelos dbt ainda estao no plano.
PIB setorial - SIDRA 1846	Delta para respostas e valores; 2.806 linhas, 122 trimestres e 23 setores; reexecucao e checagens documentadas.	Tarefas Bronze E2 por fonte concluidas; diario pendente. Carga no DuckDB e dbt ainda pendentes.
PIB - China, EUA, Russia	Tabelas de resposta e indicadores anuais em formato longo; idempotencia e checagens. Russia preserva nulos 1960-1989.	Modelos dbt/Silver e carga final analitica comum ficam para E3.
Salario minimo - DIEESE	HTML arquivado, Delta de respostas e meses, serie mensal continua e reexecucao sem duplicacao.	A metrica calculada e o cruzamento com IPCA ficam para Silver/dbt.
Clima - INMET	Catalogo de estacoes em Delta, diagnostico de API e checagens geograficas/volume.	As medicoes meteorologicas diarias nao foram ingeridas; a rota legada de medicao retornou 404.
CDC transacional - Postgres	Modelo de cadastro, produto e reajuste existe no PostgreSQL.	Captura de alteracoes para Delta nao foi implementada; prototipos, consumidor e demonstracao continuam pendentes.

A documentacao tambem entrega catalogo de consultas, onboarding, mapa de fontes, dicionarios de dados, arquitetura medallion, fluxo de dados, migrations/Postgres, receitas e evidencias. O plano detalhado por fonte e as tarefas comuns ficam em tasks_entrega_2.md; o indice docs/evidencias/e2/index.md consolida a situacao das nove frentes documentadas.

8. Evidencias quantitativas da E2

Esta pagina ajuda a mostrar escala e disciplina de dados: cada carga guarda uma resposta, extrai linhas tipadas, valida invariantes e tenta ser segura quando executada de novo. As datas sao as das paginas de evidencia originais.

Fonte / data da evidencia	Volume documentado	O que esse numero demonstra
IPCA/INPC / 11 out 2026	886 requisicoes mensais; 9.116.436 linhas na Bronze Delta; 5.992.897 observacoes no PostgreSQL; carga em ~21 min.	O Delta preserva as 3.123.539 linhas com marcadores sem valor que o caminho Postgres descarta. Reexecucao da mesma particao nao cria novas linhas.
Dolar / 11-13 out 2026	1.703 boletins de 2020 a 2026.	Bronze preserva boletins durante o dia, dado necessario para estudar variacao intradiaria.
Selic / 11-13 out 2026	1.701 observacoes diarias de 2020 a 2026.	Bronze conserva os valores publicados, antes do preenchimento de calendario usado no fluxo legado.
Commodities / 13 out 2026	31.880 cotacoes em 9 simbolos, incluindo 5.069 datas com preco nulo; 18 respostas distintas (9 importadas + 9 baixadas).	A segunda execucao nao adicionou linhas. Duas execucoes completas usaram 18 das 25 requisicoes diarias da Alpha Vantage.
PIB setorial / SIDRA 1846 / 13 out 2026	2.806 valores em 122 trimestres, 1996T1 a 2026T2, com 23 setores por trimestre.	63 respostas; importacao e reexecucao documentadas sem duplicacao. A ingestao Dagster tambem terminou sem linhas novas.
PIB China, EUA e Russia / outubro 2026	132 observacoes por pais: 66 anos x 2 indicadores (1960-2025).	Formato longo e regras de nulidade/revisao documentadas; Russia preserva anos sem valor antes de 1990.
Salario minimo / 12 out 2026	387 meses sem lacuna, jul/1994 a set/2026.	Serie mensal validada por continuidade e unicidade; reexecucao imediata adicionou zero meses.
INMET / 12 out 2026	671 estacoes em 27 UFs.	Entrega E2 e o catalogo das estacoes; nao e uma serie de clima diaria.

Como falar dos numeros: diga sempre qual tabela/camada esta contando. No IPCA, 9,1 milhoes sao linhas Delta; 6,0 milhoes sao observacoes aceitas no Postgres. Sao etapas diferentes, e a diferenca sao marcadores sem valor que foram preservados na Bronze e descartados da tabela de observacoes no Postgres.

O projeto documenta idempotencia por hash de resposta e/ou chaves de observacao: repetir uma mesma ingestao nao deve duplicar os dados. Isso nao significa que as fontes nunca revisam o historico: quando uma resposta muda, o novo conteudo pode gerar uma nova versao que precisa ser interpretada mais tarde. Na E2, evidencias quantitativas de compressao ja existem para IPCA, PIB setorial e commodities; a tarefa comum do ADR 0004 segue aberta porque o conjunto de medicacoes ainda e parcial (por exemplo, as repeticoes de commodities e PIB foram medidas em um dia, nao em uma semana).

9. O que ainda esta pendente

As caixas de selecao do plano sao um artefato importante. Elas mostram que algumas partes de ingestao por fonte estao comprovadas, mas integracao, CDC e transformacao analitica comuns ainda nao estao fechados.

Item	Situacao conforme plano/evidencias	Proximo passo tecnico
ADR 0004 e medicoes comuns	O ADR continua pendente: escolha Delta/Iceberg, mecanismo CDC, semantica de entrega, politicas de atraso e gatilho de revisao. Ha medicoes de compressao para IPCA, PIB e commodities, mas a checklist comum segue aberta.	Concluir comparacao, completar medicao de repeticoes por janela e registrar trade-offs no ADR.
CDC do Postgres	Checklist inteiro segue aberto: configuracao logica, consumidor, Delta, deduplicacao por LSN e demonstracao de mudancas.	Capturar INSERT/UPDATE/DELETE e mostrar sem duplicidade numa reexecucao apos falha.
Integracao E2	A receita just e2 existe e foi testada numa copia limpa quando cobria apenas PIB e commodities. A receita ampliada, o teste oficial por outra pessoa, CDC, diario consolidado e tag ainda estao pendentes.	Rodar a receita ampliada numa maquina/clone limpo, integrar CDC e arquivar logs/checagens antes da tag.
Carga DuckDB e dbt por fonte	Commodities e PIB 1846 ja tem evidencia Bronze Delta E2; tarefas de carga/contratos DuckDB e modelos dbt continuam pendentes em seus planos por fonte.	Migrar o consumo das tabelas e criar modelos Silver com tipos, revisoes e testes.
Clima diario	Catalogo das estacoes entregue; medicoes diarias nao coletadas. API diaria legada devolve 404.	Decidir ingestao historica pelos pacotes BDMEP e mapeamento estacao/localidade.
Silver/Gold e painel	dbt, tabelas comuns, testes de transformacao, joins entre fontes e Streamlit/Plotly sao planejados.	Criar modelos SQL, contratos e indicadores antes de apresentar interface como pronta.
Historico da cesta IPCA	Valores sao preservados; nomes/vigencias de classificacao ainda sao sobrescritos no schema atual.	Modelar versoes com vigencia e atualizar sincronizador; validar continuidade apos migracao.

Uma limitacao importante: o catalogo de consultas descreve perguntas de produto, mas nao significa que haja uma aplicacao completa para o lojista. O repositorio hoje sustenta ingestao, persistencia, documentacao e ferramentas locais; painel/experiencia final continua planejado.

10. Exemplo tecnico: da pergunta ao reajuste (consulta 5)

A consulta 5 mostra por que o projeto separa dados e preserva historico. Imagine uma loja que vende 'Leite longa vida'. O produto da loja deve apontar para a classificacao do IBGE correspondente. A partir dai, a aplicacao pode buscar a variacao do IPCA da categoria para a localidade e o periodo desejados.

Etapa	O que acontece	Por que importa
1. Associar	produto guarda uma FK para o codigo de classificacao IPCA.	Evita que o painel use uma categoria digitada com erro ou desconhecida.
2. Consultar	buscar a variacao acumulada de 12 meses para codigo + localidade + mes.	E um filtro relacional por chaves e periodo. A documentacao alerta que a serie 2938 (2006-2011) nao oferece a variavel pronta de 12 meses.
3. Calcular	se a variacao acumulada for r%, um exemplo de preco de referencia e preco_atual x (1 + r/100).	O calculo e explicavel, mas a politica comercial pode incluir margem, custo, demanda e concorrencia.
4. Registrar	se o lojista aplicar, inserir um reajuste com preco anterior, novo preco e data, dentro de uma transacao.	O historico mostra o que foi aplicado; o preco atual e derivado do ultimo evento.
5. Auditar	guardar a versao do dado e o criterio que fundamentaram a sugestao e permitir reproduzir a decisao.	Essa e a motivacao do historico append-only; a vigencia historica dos nomes da cesta ainda e uma lacuna conhecida.

Um pouco de SQL conceitual

O fluxo mental seria: selecionar a observacao IPCA da classificacao associada ao produto; validar se a localidade e a janela estao disponiveis; calcular a referencia; e inserir o evento de reajuste em uma transacao. O codigo abaixo e pseudoconsulta para explicar a ligacao, nao uma query literal do projeto:

```
SELECT produto, observacao_ipca FROM produto JOIN observacao_ipca ON produto.codigo_ipca = observacao_ipca.codigo WHERE produto.id = ? AND observacao_ipca.localidade = ? AND observacao_ipca.mes = ?;
```

O relacionamento e o ponto tecnico: a FK transforma uma regra de negocio ('este produto pertence a este subitem') numa regra que o banco consegue fiscalizar. Depois, uma transacao agrupa a validacao e a escrita, evitando metade de uma alteracao ser confirmada sem o restante.

> **Honestidade de escopo:** esse e o fluxo de negocio arquitetado pelo projeto. A documentacao mostra esquema e ingestao; nao apresenta um painel de loja ja entregue que execute toda essa jornada.

11. Roteiro para apresentar

Resumo de 60 a 90 segundos

O InflaTrack e um projeto de dados para ajudar pequenos e medios lojistas a entender a inflacao do seu setor e apoiar reajustes de preco com dados oficiais. O lojista associa seus produtos a categorias do IPCA, e a plataforma pretende combinar essas referencias com dados macroeconomicos, como dolar, Selic e PIB, para responder perguntas de periodo, regiao e sazonalidade. Tecnicamente, usamos PostgreSQL para o cadastro e o historico de reajustes, porque essa parte precisa de transacoes e integridade, e DuckDB para analise local multifonte. As fontes sao ingeridas em Python; guardamos respostas originais e estamos migrando a camada Bronze para Delta Lake, que acrescenta versionamento sobre Parquet. O Dagster coordena as cargas. A documentacao tambem registra os limites: a Silver e a Gold comuns com dbt, o CDC transacional e o painel ainda sao proximos passos. Na E2, ha evidencias de cargas reais, por exemplo mais de 9 milhoes de linhas Bronze do IPCA e 387 meses de salario minimo, sempre distinguindo o que foi testado do que esta apenas planejado.

Perguntas que podem aparecer

Pergunta	Resposta curta
Por que dois bancos?	Porque escrita transacional de preco e consulta analitica multifonte tem requisitos diferentes. PostgreSQL e DuckDB nao duplicam o mesmo papel.
Delta e Parquet sao concorrentes?	Nao exatamente. Parquet e o formato colunar; Delta organiza arquivos Parquet com um log de transacoes/versoes.
O projeto ja tem painel?	Nao ha Streamlit/Plotly no repositorio; a interface e uma decisao planejada depois da Gold.
O dado de clima esta pronto?	O catalogo de 671 estacoes esta documentado. Medicoes diarias nao foram ingeridas e a rota antiga consultada retorna 404.
O projeto preserva a cesta antiga do IPCA?	Ainda nao completamente. Os valores podem ser preservados, mas nomes/vigencias de classificacao sao sobrescritos no esquema atual; ADR 0001 deixa isso como pendencia.
Como garante reexecucao segura?	Por hash da resposta e chaves de observacao para evitar duplicacao identica; evidencias por fonte mostram reexecucoes sem novas linhas.

Glossario tecnico

Termo	Em palavras simples
OLTP	Operacao de leitura/escrita de registros pequenos, como cadastrar produto e salvar reajuste.
OLAP	Analise de muitos registros, agregacoes e cruzamentos de fontes.
Idempotencia	Repetir uma carga com a mesma resposta nao cria duplicatas.
CDC	Captura de mudancas do banco para outro destino; ainda pendente no plano.
Forward fill	Em dia sem publicacao, carregar o ultimo valor conhecido e marcar que foi preenchido.
Particao	Divisao fisica/logica dos dados, por exemplo por ano, para organizar cargas e leituras.

12. Documentos de referencia e limites deste guia

Este guia foi escrito a partir do repositorio e de suas evidencias versionadas. Para uma apresentacao, use estas paginas como fonte primaria quando precisar conferir um detalhe:

- **README.md** - Objetivo, fontes, setup e componentes principais.
- **docs/visaoGeral/consultas.md** - Catalogo das onze perguntas e motivacao de acesso.
- **docs/arquitetura/visaoGeral.md** - Mapa dos documentos e arquitetura.
- **docs/arquitetura/stackTecnologica.md** - Justificativa, alternativas, trade-offs e estado de cada tecnologia.
- **docs/arquitetura/arquiteturaMedallion.md** - Camadas e implementacao atual por fonte.
- **docs/arquitetura/fluxoDados.md** - Caminho atual/alvo das cargas.
- **docs/arquitetura.md** - ADR 0001: modelagem IPCA e vigencia da cesta.
- **docs/adr/0002-duckdb-unico.md** - ADR 0002: arquivo DuckDB unico.
- **docs/adr/0003-bcb-macro.md** - ADR 0003: calendario e series do BCB.
- **tasks_entrega_2.md** - Plano da E2/E3 e itens que seguem abertos.
- **docs/evidencias/e2/*.md** - Nove paginas de evidencias por frente, com numeros e comandos.
- **migrations/0002_lojista.sql** - Modelo transacional de lojista, produto, reajuste e preco atual.

O status de pendencias foi conferido contra as caixas do plano e as paginas de evidencia, e nao foi inferido apenas dos diagramas. Os dados quantitativos foram copiados das execucoes documentadas, realizadas entre 11 e 13 de outubro de 2026. Este guia nao reexecutou cargas de APIs nem benchmark de consultas.

A revisao documental que acompanha o PR atualiza o registro tecnologico, corrige referencias de ADR, explicita o estado da Bronze/Silver/Gold e harmoniza o ADR 0003 com os loaders existentes. O PR nao muda o schema nem conclui as pendencias listadas.

Para a apresentacao, volte sempre a tres pontos: **qual problema de decisao do lojista**, **como os dados chegam e sao protegidos**, e **o que a equipe ja comprovou versus o que ainda e alvo**.